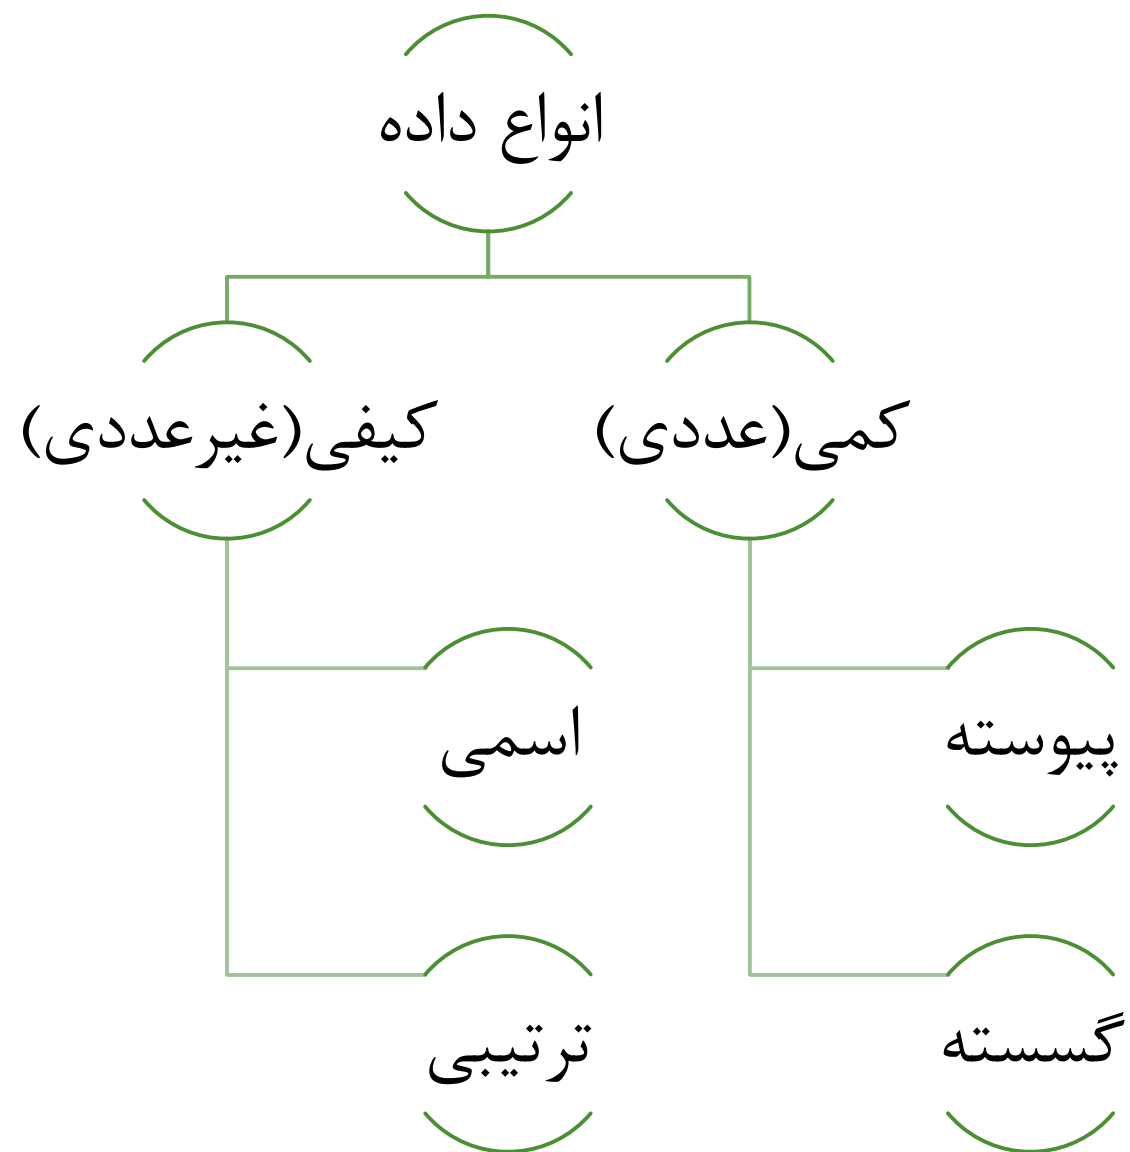


ضروریات آمار برای علم داده

مروری بر انواع داده و توزیع‌های آماری و مفهوم ناپارامتری



متغیر تصادفی

Outcome	X	Probability
NNN	0	$3/4 * 3/4 * 3/4$
NND	1	$3/4 * 3/4 * 1/4$
NDN	1	$3/4 * 1/4 * 3/4$
DNN	1	$1/4 * 3/4 * 3/4$
NDD	2	$3/4 * 1/4 * 1/4$
DND	2	$1/4 * 3/4 * 1/4$
DDN	2	$1/4 * 1/4 * 3/4$
DDD	3	$1/4 * 1/4 * 1/4$

► یک متغیر تصادفی تابعی از فضای نمونه به مجموعه اعداد حقیقی است، به طوری که به هر نقطه از فضای نمونه یک عدد حقیقی را نسبت می‌دهد.

► برای نمایش متغیر تصادفی از حروف بزرگ مانند X, Y, \dots استفاده می‌شود.

► برای نمایش یکی از مقادیری که متغیر تصادفی اختیار می‌کند از حروف کوچک معادل آن استفاده می‌شود.

► مجموعه مقادیر و یا برد متغیر تصادفی X را با S_X نمایش می‌دهند و آن را تکیه‌گاه X می‌گویند.

► متغیر تصادفی گسسته: متغیر تصادفی که مجموعه مقادیر آن متناهی یا نامتناهی شمارش‌پذیر باشد

► متغیر تصادفی پیوسته: متغیر تصادفی که مجموعه مقادیر آن یک فاصله عددی یا اجتماع چند فاصله عددی باشد.

داده‌ها

پارامتری


- ★ رفتار داده‌ها شناسایی شده است و اطلاعاتی در زمینه‌ی شکل تابع چگالی توزیع و پارامترهای مورد نیاز برای مشخص‌سازی دقیق داریم.
- ★ فرم بسته‌ای از تابع چگالی کشف شده است
- ★ روابط بین توزیع‌های مختلف اثبات شده است و قضایای موجود در مورد برخی توزیع‌های جهت کاهش درجه سختی مسئله
- ★ امکان داده‌افزایی و شبیه‌سازی و تولید نمونه در صحت سنجی مدل

ناپارامتری



شکل داده‌ها شناخته شده نیست و تعریف مشخصی ندارد یعنی فرم بسته‌ای برای نمونه مشاهده شده یافت نشده است، این موضوع می‌تواند نشأت گرفته از خاص بودن مجموعه داده مورد نظر باشد و توزیع‌های پارامتری بیشتر روی پدیده‌های پرتکرارتر با شکل مشخص به وجود آمده‌اند.

تابع چگالی احتمال





1. $f(x) \geq 0$ for all x
2. $\int_{-\infty}^{\infty} f(x) dx = \text{area under the entire graph of } f(x)$
 $= 1$

تابع توزیع تجمعی

➤ تعریف تابع توزیع تجمعی

$$F_X(x) = P(X \leq x) = \sum_{t \leq x} P(t)$$

$$F(x) = \int_{-\infty}^x f(t) dt$$



تابع توزیع تجمعی

➤ تمام توابع توزیع تجمعی صعودی (ولی نه لزوماً اکیدا صعودی) و از راست پیوسته هستند.

اگر $x_1 \leq x_2$ باشد آنگاه:

$$F_X(x_1) \leq F_X(x_2)$$

➤ بین بازه صفر و یک است

$$0 \leq F_X(x) \leq 1$$

➤ حد آن در منفی بی‌نهایت صفر و در مثبت بی‌نهایت یک است

$$\lim_{x \rightarrow -\infty} F(x) = 0$$

$$\lim_{x \rightarrow +\infty} F(x) = 1$$

$$P(X > x) = 1 - F_X(x)$$

➤

ارتباط تابع توزیع تجمعی و چگالی (جرم) احتمال

continues

$$F(x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = \frac{d}{dx} F(x)$$

categorical


$$F_X(x) = P(X \leq x) = \sum_{t \leq x} P(t)$$

$$\Pr(X = x) = F(x_0) - F(x_0 -)$$

توزیع برنولی

$$X \sim \text{Bernoulli}(p)$$


$$P_X(x) = \begin{cases} p & \text{for } x = 1 \\ 1 - p & \text{for } x = 0 \\ 0 & \text{otherwise} \end{cases}$$



توزیع دوجمله‌ای

$$X \sim \text{Binomial}(n, p)$$

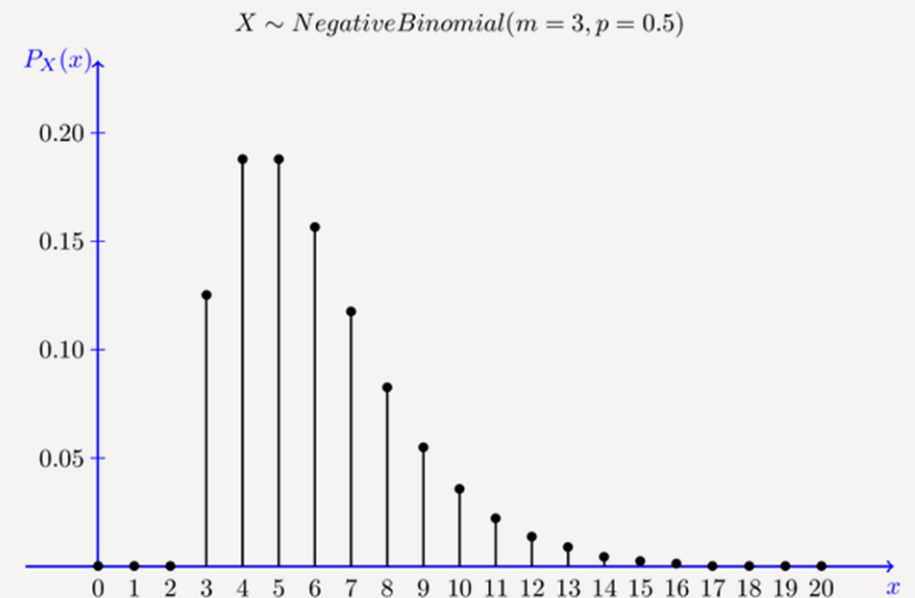
$$P_X(k) = \begin{cases} \binom{n}{k} p^k (1-p)^{n-k} & \text{for } k = 0, 1, 2, \dots, n \\ 0 & \text{otherwise} \end{cases}$$



توزیع دوجمله‌ای منفی

$$X \sim \text{Pascal}(m, p)$$


$$P_X(k) = \begin{cases} \binom{k-1}{m-1} p^m (1-p)^{k-m} & \text{for } k = m, m+1, m+2, m+3, \dots \\ 0 & \text{otherwise} \end{cases}$$



توزیع هندسی

$$X \sim \text{Geometric}(p)$$


$$P_X(k) = \begin{cases} p(1-p)^{k-1} & \text{for } k = 1, 2, 3, \dots \\ 0 & \text{otherwise} \end{cases}$$



توزيع بواسون

$$X \sim \text{Poisson}(\lambda)$$


$$P_X(k) = \begin{cases} \frac{e^{-\lambda} \lambda^k}{k!} & \text{for } k \in R_X \\ 0 & \text{otherwise} \end{cases}$$



توزیع یکنواخت پیوسته

$$X \sim \text{Uniform}(a, b)$$

$$f_X(x) = \begin{cases} \frac{1}{b-a} & a < x < b \\ 0 & x < a \text{ or } x > b \end{cases}$$







توزيع نرمال

$$X \sim N(\mu, \sigma^2)$$

$$f_X(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\},$$

$$F_X(x) = P(X \leq x) = \Phi\left(\frac{x-\mu}{\sigma}\right),$$


$$P(a < X \leq b) = \Phi\left(\frac{b-\mu}{\sigma}\right) - \Phi\left(\frac{a-\mu}{\sigma}\right).$$



توزیع نمایی

$$X \sim \text{Exponential}(\lambda)$$

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x} & x > 0 \\ 0 & \text{otherwise} \end{cases}$$



توزيع گاما

$$X \sim \text{Gamma}(\alpha, \lambda)$$

$$f_X(x) = \begin{cases} \frac{\lambda^\alpha x^{\alpha-1} e^{-\lambda x}}{\Gamma(\alpha)} & x > 0 \\ 0 & \text{otherwise} \end{cases}$$

